

Analyse NLP des Discours Présidentiels Américains

Explorer l'évolution du langage politique à travers l'Histoire

1 Introduction

Les discours présidentiels ne sont pas de simples prises de parole. Ils sont des témoins historiques.

Chaque président américain utilise son discours d'investiture pour transmettre une vision, rassurer une nation, répondre à une crise ou encore inspirer l'avenir. Derrière chaque mot se cachent des émotions, des stratégies politiques et des contextes historiques majeurs.

Dans ce projet, nous avons cherché à répondre à une question centrale :

Comment le langage politique américain a-t-il évolué au fil du temps ?

Pour répondre à cette problématique, nous avons utilisé les techniques du **Natural Language Processing (NLP)** afin d'analyser automatiquement plusieurs discours présidentiels américains.

À travers :

- l'analyse de sentiment,
- l'étude des mots les plus fréquents,
- les techniques TF-IDF,
- et différentes visualisations de données,

nous avons pu découvrir les tendances linguistiques et émotionnelles qui traversent l'histoire politique des États-Unis.

Ce projet combine donc :

- data science,
- linguistique computationnelle,
- analyse historique,
- et visualisation de données.

2 Objectifs du projet

L'objectif principal du projet est d'extraire des informations pertinentes à partir des discours présidentiels afin de comprendre :

- les thèmes récurrents dans les discours,
- les émotions dominantes,
- l'évolution du vocabulaire politique,
- les différences de style entre présidents,
- l'impact des contextes historiques sur le langage utilisé.

Plus précisément, nous avons voulu :

- ✓ Identifier les mots-clés les plus importants
- ✓ Mesurer la tonalité émotionnelle des discours
- ✓ Observer l'évolution des sentiments au fil du temps
- ✓ Comparer les présidents selon leur style linguistique
- ✓ Visualiser les tendances politiques à travers les données

3 Présentation du Dataset

Le dataset utilisé provient de Kaggle :

Presidential Inaugural Addresses Dataset

Il regroupe les discours d'investiture de plusieurs présidents américains sur différentes périodes historiques.

Colonnes principales

Colonne	Description
Name	Nom du président
Inaugural Address	Type du discours
Date	Date du discours
text	Texte complet du discours

4 Architecture du projet

Le projet est organisé de manière modulaire afin de faciliter l'analyse et la maintenance du code.

Structure du projet

```
PRESIDENTIAL - SPEECHES - NLP /
|
|-- data/
|   '-- inaug_speeches.csv
|
|-- notebooks/
|   '-- analysis.ipynb
|
```

```

|-- src/
|   |-- preprocessing.py
|   |-- sentiment_analysis.py
|   '-- tfidf_analysis.py
|
|-- visuals/
|   |-- sentiment_over_time.png
|   |-- wordcloud.png
|   |-- tfidf_barplot.png
|   '-- ...
|
|-- README.md
'-- requirements.txt

```

Cette architecture permet de séparer :

- le traitement des données,
- les analyses NLP,
- les visualisations,
- et les expérimentations réalisées dans les notebooks.

5 Prétraitement des données

Avant toute analyse NLP, les données textuelles doivent être nettoyées et standardisées.

Cette étape est cruciale car un texte brut contient énormément de bruit :

- ponctuation,
- caractères spéciaux,
- mots inutiles,
- variations grammaticales.

Sans prétraitement, les résultats seraient peu fiables.

5.1 Nettoyage du texte

Les opérations suivantes ont été appliquées :

- conversion en minuscules,
- suppression de la ponctuation,
- suppression des caractères spéciaux,
- suppression des espaces inutiles.

Exemple :

```

"Freedom, Democracy & Hope!"
      ↓
"freedom democracy hope"

```

5.2 Tokenisation

La tokenisation consiste à découper le texte en unités élémentaires appelées *tokens*.

Exemple :

"We the people"
↓
["we", "the", "people"]

Cette étape a été réalisée avec la bibliothèque **NLTK**.

5.3 Suppression des Stopwords

Les stopwords sont des mots très fréquents mais peu utiles pour l'analyse :

- the
- and
- of
- is
- to

Leur suppression permet de conserver uniquement les mots ayant une forte valeur sémantique.

5.4 Lemmatisation

La lemmatisation ramène les mots à leur forme de base.

Mot original	Lemme
running	run
citizens	citizen
democracies	democracy

Cette technique améliore la qualité des analyses statistiques.

5.5 POS Tagging et NER

Le projet utilise également **spaCy** pour :

POS Tagging

Identifier la catégorie grammaticale des mots :

- noms,
- verbes,
- adjectifs,
- adverbes.

Named Entity Recognition (NER)

Détecter automatiquement :

- les personnes,
- les organisations,
- les lieux,
- les événements historiques.

Cette étape apporte une dimension plus intelligente à l'analyse textuelle.

6 Analyse de sentiment

L'un des objectifs majeurs du projet était de mesurer les émotions présentes dans les discours.

Pour cela, nous avons utilisé **VADER** (*Valence Aware Dictionary and sEntiment Reasoner*).

Fonctionnement de VADER

VADER attribue plusieurs scores :

Score	Signification
Positive	Tonalité positive
Negative	Tonalité négative
Neutral	Neutralité
Compound	Score global